

Relatório técnico — baseline clássico de análise de sentimentos

Autor: Henrique Barone

Corpus: B2W-Reviews01

Tarefa: classificação binária de sentimentos em português brasileiro

1. Objetivo e protocolo

O estudo comparou duas representações vetoriais clássicas — Bag of Words (BoW) e TF-IDF — com cinco classificadores supervisionados: Multinomial Naive Bayes, Regressão Logística, SVM linear, Random Forest e Gradient Boosting. Não foram usados deep learning, LLMs nem modelos pré-treinados para classificação.

O corpus oficial possui **132.373 avaliações**. A distribuição original das notas é: 27.369 avaliações de 1 estrela (20,68%), 8.389 de 2 (6,34%), 16.315 de 3 (12,33%), 32.345 de 4 (24,43%) e 47.955 de 5 estrelas (36,23%). Portanto, o corpus é desbalanceado em favor das notas altas.

Para formar o problema binário, notas 1–2 foram rotuladas como negativas e 4–5 como positivas; notas 3 foram removidas por representarem neutralidade/ambiguidade. Também foram removidos textos ausentes ou vazios e 2.206 duplicatas exatas antes da divisão, impedindo que o mesmo texto aparecesse em treino e teste. O corpus binário resultante possui **110.882 textos**: 32.601 negativos (29,40%) e 78.281 positivos (70,60%).

A análise descritiva considerou o corpus completo. Os dez experimentos utilizaram uma amostra estratificada e reproduzível de 30.000 textos, decisão necessária para viabilizar os ensembles de árvores em computadores comuns. A divisão foi estratificada em 24.000 exemplos de treino e 6.000 de teste, com semente 42. O conjunto de teste contém 1.764 negativos e 4.236 positivos e não foi usado para ajustar vocabulário, pesos IDF ou hiperparâmetros.

2. Pré-processamento e representações

O texto passou por normalização Unicode NFKC, conversão para minúsculas, remoção de HTML, URLs e símbolos, tokenização e lematização em português com spaCy e remoção das stopwords portuguesas do NLTK. Foram preservadas as negações `não`, `nem`, `nunca`, `jamaiz` e `sem`, pois têm papel semântico decisivo no sentimento. Acentos também foram preservados. O spaCy foi usado exclusivamente no pré-processamento linguístico, não como classificador.

BoW representa cada documento por contagens dos termos; TF-IDF reduz o peso de termos frequentes em muitos documentos e realça termos relativamente discriminativos. As duas representações usaram unigramas e bigramas, `min_df=2` e no máximo 8.000 atributos. Somente o treino foi usado no `fit`; o teste foi apenas transformado.

Os hiperparâmetros foram mantidos próximos aos padrões e alterados apenas por convergência, desbalanceamento, reprodutibilidade ou custo computacional. Regressão Logística e SVM usaram pesos balanceados; Random Forest usou 150 árvores e balanceamento por bootstrap; Gradient Boosting usou 100 estimadores e `max_features='sqrt'`. Para SVM foi escolhido `LinearSVC`, adequado à alta dimensionalidade esparsa de texto.

3. Resultados no conjunto de teste


Precisão, revocação e F1 são **macro-médias**, atribuindo a mesma importância às classes negativa e positiva. A tabela está ordenada por F1 macro.

Representação	Classificador	Acurácia	Precisão macro	Revocação macro	F1 macro
BoW	Regressão Logística	0,9365	0,9209	0,9276	0,9241
TF-IDF	Regressão Logística	0,9323	0,9108	0,9331	0,9207
TF-IDF	SVM	0,9332	0,9148	0,9274	0,9207
TF-IDF	Naive Bayes	0,9298	0,9157	0,9152	0,9154
BoW	Naive Bayes	0,9277	0,9061	0,9258	0,9150
BoW	SVM	0,9235	0,9071	0,9091	0,9081
BoW	Random Forest	0,9100	0,8850	0,9073	0,8948
TF-IDF	Random Forest	0,9070	0,8809	0,9062	0,8918
BoW	Gradient Boosting	0,8762	0,8912	0,8063	0,8345
TF-IDF	Gradient Boosting	0,8755	0,8892	0,8061	0,8339

A melhor combinação foi **Regressão Logística + BoW**, com acurácia 0,9365 e F1 macro 0,9241. Isso mostra que as contagens brutas, associadas à regularização do modelo linear, preservaram sinais úteis de intensidade e frequência neste corpus.

Na média dos cinco classificadores, porém, TF-IDF obteve F1 macro 0,8965 contra 0,8953 do BoW: vantagem pequena, de 0,0012. O efeito dependeu do algoritmo. TF-IDF melhorou especialmente o SVM (+0,0126 de F1), foi praticamente neutro no Naive Bayes e Gradient Boosting e reduziu ligeiramente o desempenho de Random Forest e Regressão Logística. Portanto, não existe superioridade universal da representação; a interação entre representação e hipótese do classificador é relevante.

4. Matriz de confusão do melhor modelo



Real \ Predita	Negativa	Positiva
Negativa	1.598	166
Positiva	215	4.021

Foram classificados corretamente 1.598 negativos e 4.021 positivos. Houve 166 falsos positivos e 215 falsos negativos. Embora o número absoluto de falsos negativos seja maior, proporcionalmente a taxa de erro foi maior entre avaliações negativas ($166/1.764 = 9,41\%$) do que entre positivas ($215/4.236 = 5,08\%$). Isso confirma a importância de observar métricas macro e matriz de confusão em vez de somente acurácia.

5. Análise de erros

O melhor modelo apresentou 381 erros. Para a análise qualitativa, foi examinada uma amostra reprodutível de falsos positivos e falsos negativos. Três padrões se destacaram:

- Contraste e avaliações mistas.** Uma avaliação de 2 estrelas elogia “boa qualidade de som” e “botões úteis”, mas depois critica encaixe, estabilidade e bateria. BoW soma pistas positivas e negativas sem modelar bem qual trecho domina a conclusão.
- Negação e comparação.** Em uma avaliação de 1 estrela, “a fixação [...] sempre foi muito boa” aparece antes de “não dura 20 minutos”. Os termos positivos do contexto comparativo podem superar a crítica atual.
- Nota e texto parcialmente divergentes.** Avaliações de 5 estrelas como “É caro, mas dura muito” e “Qualidade e preço justo. Mas falta a capinha” possuem ressalvas fortes, gerando falsos

negativos. Há também textos curtos, erros ortográficos e referências implícitas que as representações esparsas não resolvem.

Esses casos evidenciam limites clássicos de BoW/TF-IDF: pouca representação de ordem longa, composição, alvo do sentimento, ironia e mudança de polaridade dentro do texto. Bigramas ajudam com expressões locais como “não dura”, mas não resolvem integralmente os fenômenos discursivos.

6. Limitações

Os resultados correspondem a uma amostra estratificada de 30 mil avaliações e a uma única divisão treino–teste. Portanto, pequenas diferenças entre modelos não devem ser interpretadas como evidência de superioridade estatística. O experimento também não realizou busca de hiperparâmetros, pois o objetivo principal era comparar representações mantendo um baseline clássico e reproduzível.

7. Conclusão

O experimento cumpriu o pipeline clássico de NLU e avaliou as dez combinações no mesmo teste isolado. Modelos lineares foram superiores aos ensembles de árvores para os vetores esparsos de alta dimensão. Regressão Logística + BoW é o baseline recomendado para a comparação posterior com sistemas generativos, enquanto TF-IDF + SVM apresentou desempenho quase equivalente e demonstrou que o efeito da ponderação TF-IDF é dependente do classificador.

Os resultados são reproduzíveis a partir do notebook executado, da semente fixa e das dependências versionadas. Os valores completos estão também em [artifacts/resultados_comparativos.csv](#), e as dez matrizes em [artifacts/matrizes_confusao_todas.png](#).

Referências

- Americanas Tech. **B2W-Reviews01**. Repositório oficial: <https://github.com/americanas-tech/b2w-reviews01>.
- Real, L.; Oshiro, M.; Mafra, A. *B2W-Reviews01: an open product reviews corpus*. STIL, 2019. PDF disponível no repositório oficial.
- scikit-learn. *Feature extraction e Supervised learning*: <https://scikit-learn.org/stable/>.